

Operating System

তোমার RHCE background থাকায় এটা সহজ সিদ্ধান্ত:

Option	সুপারিশ
Ubuntu LTS (22.04/24.04) বা Fedora	✅ সবচেয়ে ভালো choice — Windows-এর চেয়ে হালকা, RAM/CPU কম খরচ করে, আর তুমি Linux-এ already comfortable
Windows + WSL2	যদি Windows ছাড়তে না চাও, তাহলে WSL2-তে Ubuntu install করে develop করো

২৫৬ GB SSD-তে Windows একাই ২৫-৩০ GB নিয়ে নেয়। Linux native install করলে অনেক বেশি জায়গা বাঁচবে।

IDE / Code Editor

Tool	কেন
VS Code ✅	হালকা (RAM কম খায়), Python + Jupyter + AI সবকিছুর জন্য extension আছে, industry-standard
~~PyCharm~~ ❌	Professional edition ভারী, তোমার 12GB RAM-এ VS Code + browser + terminal একসাথে চালানো বেশি smooth হবে

দরকারি VS Code Extensions:

- Python (Microsoft)
- Pylance
- Jupyter
- GitLens
- autoDocstring
- Thunder Client (Postman-এর lightweight বিকল্প, API test করার জন্য)

Python & Package Management

Tool	কাজ
Python 3.11+	মূল language
uv ✅	pip-এর চেয়ে অনেক দ্রুত এবং কম disk space নেয় — venv তৈরি ও package install-এর জন্য এটাই ব্যবহার করো (MCP-র official docs-ও uv সাজেস্ট করে)

Tool	কাজ
~~Anaconda~~ ✗	এড়িয়ে যাও — ৩-৪ GB জায়গা নেয় শুধু install করতেই, তোমার 256GB-তে এটা luxury না
<pre>curl -LsSf https://astral.sh/uv/install.sh sh</pre>	
<pre>uv venv</pre>	
<pre>uv add langchain fastmcp chromadb</pre>	

🔧 আরও দরকারি Tools

Tool	কেন লাগবে
Git + GitHub account	Code version control, project রাখা
Node.js (LTS)	MCP Inspector চালাতে লাগবে (npx @modelcontextprotocol/inspector)
Docker (হালকা ব্যবহার)	পরে MCP server deploy practice করার জন্য — শুরুতে জরুরি না, পরে শিখলেই হবে

☁ GPU না থাকার সমাধান — Cloud API ব্যবহার করো

এটাই তোমার জন্য সবচেয়ে গুরুত্বপূর্ণ পয়েন্ট। GPU না থাকা কোনো সমস্যাই না, কারণ:

- তোমাকে নিজে কোনো model train/run করতে হবে না — Claude, GPT, Llama সব cloud API দিয়ে call করবে
- ফ্রি API account বানাও:
 - **Groq** — ফ্রি, অসম্ভব দ্রুত, Llama/Mixtral model access দেয়
 - **Anthropic Console** বা **OpenAI** — pay-as-you-go, শুরুতে সামান্য খরচেই অনেক কাজ হবে
- এভাবে তোমার CPU-তে শুধু request পাঠানো আর response handle করার কাজ হবে — ভারী কম্পিউটেশন cloud-এ হবে

🔧 RAG Practice-এর জন্য হালকা Local Tools

Tool	কেন হালকা
ChromaDB	CPU-তেই ভালো চলে, GPU লাগে না

Tool

কেন হালকা

sentence-transformers
(all-MiniLM-L6-v2 model)

মাত্র ~80MB, embedding তৈরির জন্য যথেষ্ট, GPU ছাড়াই চলে

Ollama (optional, শুধু ছোট model)

যদি local model test করতে চাও, শুধু 1B-3B parameter-এর ছোট model (যেমন llama3.2:1b, qwen2.5:1.5b) ব্যবহার করো — বড় model (7B+) তোমার CPU-তে খুবই ধীর হবে

⚠ তোমার Setup-এর জন্য বিশেষ সতর্কতা

- 256GB SSD সীমিত** — প্রতিটা project-এ আলাদা venv বানাতে duplicate packages জমে জায়গা কমে যাবে। uv ব্যবহার করলে এটা কম হয় (shared cache রাখে)।
- 12GB RAM** — একসাথে VS Code + Docker + বড় local model চালানো এড়িয়ে চলো। একটা সময়ে একটাই ভারী কাজ।
- GPU নেই মানে local training/fine-tuning এখনকার জন্য skip** — এটা এখন দরকারও নেই, তোমার লক্ষ্য (Agentic AI, RAG, MCP) মূলত API-based কাজ, GPU ছাড়াই পুরোপুরি সম্ভব।

তোমার system এই কাজের জন্য পুরোপুরি যথেষ্ট — কারণ তুমি model বানাবে না, ব্যবহার করবে। Setup-টা lightweight রাখলে smooth ভাবে কাজ করতে পারবে।